

UNIVERSIDAD PANAMERICANA
CIUDAD UP · FACULTAD DE CIENCIAS EMPRESARIALES

Tarea

Series de Tiempo para Finanzas

ARIMA(p, d, q) · SARIMA · SARIMAX · Pronóstico

Dr. César Galindo

Verano 2026

1. Procesos estacionarios y fundamentos

Definiciones y notación — Procesos estacionarios

Estacionariedad débil (de covarianza). El proceso $\{Y_t\}_{t \in \mathbb{Z}}$ es *débilmente estacionario* si: (i) $\mathbb{E}[Y_t] = \mu$ para todo t ; (ii) $\text{Cov}(Y_t, Y_{t-k}) = \gamma(k)$ depende sólo de k .

Estacionariedad estricta. La distribución conjunta de $(Y_{t_1}, \dots, Y_{t_m})$ coincide con la de $(Y_{t_1+h}, \dots, Y_{t_m+h})$ para todo h y toda elección de índices.

ACF y PACF. $\rho(k) = \gamma(k)/\gamma(0)$: *función de autocorrelación* (ACF). La *función de autocorrelación parcial* (PACF) $\alpha(k)$ es la correlación entre Y_t e Y_{t-k} eliminando el efecto lineal de $Y_{t-1}, \dots, Y_{t-k+1}$.

Operador de rezago. $BY_t = Y_{t-1}$; $B^k Y_t = Y_{t-k}$; $\Delta = (1 - B)$.

Ruido blanco. $\{\varepsilon_t\} \sim \text{WN}(0, \sigma^2)$: media cero, varianza σ^2 , no correlacionado.

Procesos ARMA(p, q). $\Phi(B)Y_t = \Theta(B)\varepsilon_t$, donde $\Phi(z) = 1 - \phi_1 z - \dots - \phi_p z^p$ y $\Theta(z) = 1 + \theta_1 z + \dots + \theta_q z^q$. Condición de *estacionariedad*: las raíces de $\Phi(z)$ están fuera del círculo unitario. Condición de *invertibilidad*: las raíces de $\Theta(z)$ están fuera del círculo unitario.

Patrones de identificación:

- AR(p): PACF se corta en el rezago p ; ACF decae (exponencial u oscilante).
- MA(q): ACF se corta en el rezago q ; PACF decae.
- ARMA(p, q): ambas ACF y PACF decaen sin corte abrupto.
- Ruido blanco: ACF y PACF ≈ 0 para todo $k \geq 1$.

Raíz unitaria. Y_t tiene raíz unitaria si $\Phi(1) = 0$; implica no estacionariedad. La primera diferencia ΔY_t suele ser estacionaria (proceso $I(1)$).

Ejercicio 1.1 (Estacionariedad, ACF y PACF). Sea $\{Y_t\}_{t \in \mathbb{Z}}$ un proceso estocástico en tiempo discreto.

- Defina estacionariedad débil y estricta. Dé un ejemplo de un proceso débilmente estacionario que *no* sea estrictamente estacionario.
- Demuestre que $|\rho(k)| \leq 1$ y que $\rho(k) = \rho(-k)$.
- Sea $Y_t = 0.6 Y_{t-1} + \varepsilon_t$ con $\varepsilon_t \sim \text{WN}(0, \sigma^2)$. Calcule $\text{Var}(Y_t)$, $\text{Cov}(Y_t, Y_{t-1})$ y demuestre que $\rho(k) = 0.6^k$ para $k \geq 0$.
- Describa el patrón de ACF y PACF de un AR(1) con $\phi > 0$, un MA(1) con $\theta > 0$, y un ruido blanco. ¿Por qué estos patrones sirven para identificar el

orden del modelo?

Ejercicio 1.2 (Procesos AR, MA y ARMA). El operador de rezago B se define por $BY_t = Y_{t-1}$.

- Para el AR(2): $Y_t = 1.2Y_{t-1} - 0.32Y_{t-2} + \varepsilon_t$. Calcule las raíces del polinomio $\Phi(z) = 1 - 1.2z + 0.32z^2$ y determine si el proceso es estacionario.
- Para el MA(2): $Y_t = \varepsilon_t + 0.5\varepsilon_{t-1} - 0.3\varepsilon_{t-2}$. Calcule $\text{Var}(Y_t)$, $\text{Cov}(Y_t, Y_{t-1})$, $\text{Cov}(Y_t, Y_{t-2})$ y $\text{Cov}(Y_t, Y_{t-k})$ para $k \geq 3$.
- ¿Cuándo es invertible un MA(q)? Enuncie la condición en términos de las raíces de $\Theta(z)$ y explique su importancia para el pronóstico.
- Demuestre la representación MA(∞) de un AR(1) estacionario: si $|\phi| < 1$, entonces $Y_t = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}$.

Ejercicio 1.3 (Raíces unitarias y prueba de Dickey-Fuller). (a) Demuestre que la caminata aleatoria $Y_t = Y_{t-1} + \varepsilon_t$ no es estacionaria calculando $\text{Var}(Y_t) = t\sigma^2$ y $\text{Cov}(Y_t, Y_s) = \min(s, t)\sigma^2$.

- Sea $\Delta Y_t = Y_t - Y_{t-1}$. Muestre que $\Delta Y_t = \varepsilon_t$ para la caminata aleatoria.
- La prueba ADF contrasta $H_0 : \delta = 0$ en $\Delta Y_t = \mu + \delta Y_{t-1} + \sum_{j=1}^k \psi_j \Delta Y_{t-j} + \varepsilon_t$. Explique por qué bajo H_0 el estadístico de $\hat{\delta}$ no sigue una distribución t clásica.
- En finanzas, los log-precios suelen ser $I(1)$ y los log-retornos $I(0)$. Explique la diferencia y su implicación para el modelado y la predicción.

2. Modelos ARIMA(p, d, q)

Definiciones y notación — ARIMA

Proceso ARIMA(p, d, q). $\Phi(B)(1 - B)^d Y_t = \Theta(B)\varepsilon_t$, donde d es el orden de diferenciación. Para $d = 1$: se aplica el modelo ARMA(p, q) a ΔY_t .

Criterios de información.

$$\text{AIC} = -2 \log \hat{L} + 2k,$$

$$\text{BIC} = -2 \log \hat{L} + k \log n,$$

donde $\hat{L}$ es la verosimilitud maximizada, k el número de parámetros y n el tamaño de muestra. BIC penaliza más la complejidad cuando $n > 7$.

Procedimiento de Box-Jenkins.

- (i) *Identificación*: graficar Y_t , ACF, PACF; aplicar diferencias si es necesario.
- (ii) *Estimación*: estimar parámetros por MV o mínimos cuadrados condicionales.
- (iii) *Diagnóstico*: verificar que los residuos sean ruido blanco; si no, revisar el orden.

Prueba de Ljung-Box. $Q = n(n+2) \sum_{k=1}^h \hat{\rho}_k^2 / (n-k) \sim \chi^2(h-p-q)$ bajo H_0 : residuos son ruido blanco. Se usa $h = \min(10, n/5)$.

Pronóstico. El pronóstico óptimo (mínimo ECM lineal) es $\hat{Y}_{T+h|T} = \mathbb{E}[Y_{T+h} | Y_T, Y_{T-1}, \dots]$. Para un ARIMA($p, 1, q$): se predice ΔY_{T+h} y se acumula desde Y_T .

Cointegración. Dos series $I(1)$ son *cointegradas* si existe β tal que $Z_t = Y_t - \beta X_t$ es $I(0)$. El vector $(1, -\beta)$ es el *vector de cointegración*.

Ejercicio 2.1 (Identificación, estimación y diagnóstico). (a) Para cada patrón hipotético de ACF y PACF, identifique el orden del modelo:

- (i) ACF decae exponencialmente; PACF se corta en el rezago 2.
 - (ii) ACF se corta en el rezago 1; PACF decae exponencialmente.
 - (iii) Ambas ACF y PACF decaen sin cortarse abruptamente.
 - (iv) ACF tiene pico significativo en el rezago 1 y es aproximadamente cero después.
- (b) Explique los criterios AIC y BIC. ¿Cuál penaliza más la complejidad del modelo y en qué condición sobre n ?
- (c) Describa el procedimiento de Box-Jenkins en tres etapas. ¿Qué gráficas se inspeccionan en cada etapa?
- (d) Enuncie la prueba de Ljung-Box y explique cómo usarla con $h = \min(10, n/5)$ rezagos para diagnosticar los residuos de un modelo ARIMA.

Ejercicio 2.2 (ARIMA(1, 1, 1) para log-precios de una acción). Sea P_t el precio de una acción y $y_t = \log P_t$. Se ajusta:

$$(1 - \phi_1 B)(1 - B)y_t = (1 + \theta_1 B)\varepsilon_t, \quad \varepsilon_t \sim \text{WN}(0, \sigma^2).$$

- (a) Defina $r_t = \Delta y_t$. Muestre que el modelo se convierte en un ARMA(1, 1) para r_t y escriba la ecuación explícitamente.
- (b) Con $\hat{\phi}_1 = 0.15$ y $\hat{\theta}_1 = -0.08$, calcule el pronóstico $\hat{r}_{T+1|T} = \hat{\phi}_1 r_T + \hat{\phi}_1 \hat{\theta}_1 \varepsilon_{T-1} + \hat{\theta}_1 \varepsilon_T$.
- (c) Construya el intervalo de predicción al 95% para r_{T+1} : $\hat{r}_{T+1|T} \pm 1.96\hat{\sigma}$. Traduzca a un intervalo para $P_{T+1} = P_T \exp(r_{T+1})$.
- (d) ¿El modelo ARIMA(1, 1, 1) captura el efecto de asimetría en volatilidad (caídas del mercado generan más volatilidad que subidas equivalentes)? ¿Qué característica del modelo sería necesaria para capturarlo?

Ejercicio 2.3 (Pronóstico con ARIMA y horizonte múltiple). Sea $\{Y_t\}$ un proceso ARIMA(2, 1, 0): $(1 - \phi_1 B - \phi_2 B^2)(1 - B)Y_t = \varepsilon_t$ con $\phi_1 = 0.5$, $\phi_2 = -0.2$, $\sigma^2 = 1$.

- (a) Defina $W_t = \Delta Y_t$ y escriba la ecuación del AR(2) para W_t .
- (b) Con $Y_T = 100$, $W_T = 1.2$, $W_{T-1} = 0.8$, calcule $\hat{W}_{T+1|T}$ y $\hat{W}_{T+2|T}$.
- (c) Calcule el ECM de predicción a horizonte h : $\text{MSE}_h = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2$, donde $\psi_0 = 1$, $\psi_1 = \phi_1$ y $\psi_j = \phi_1 \psi_{j-1} + \phi_2 \psi_{j-2}$. Obtenga ψ_0, ψ_1, ψ_2 .
- (d) Construya los intervalos de predicción al 95% para W_{T+1} y W_{T+2} , y tradúzcalos a intervalos para Y_{T+1} e Y_{T+2} .

Ejercicio 2.4 (Cointegración y *spreads* estadísticos). Dos series Y_t y X_t son cointegradas si ambas son $I(1)$ pero $Z_t = Y_t - \beta X_t$ es estacionaria $I(0)$.

- (a) Enuncie el teorema de representación de Granger: si Y_t y X_t están cointegradas, existe una representación de corrección de error (ECM): $\Delta Y_t = \alpha(Y_{t-1} - \beta X_{t-1}) + \sum_j \gamma_j \Delta Y_{t-j} + \sum_j \delta_j \Delta X_{t-j} + \varepsilon_t$. Explique el término de corrección $\alpha(Y_{t-1} - \beta X_{t-1})$.
- (b) En *pairs trading*, se explotan dos activos altamente correlacionados. ¿Cómo estimar β y verificar la cointegración mediante la prueba de Engle-Granger?
- (c) Suponga que el *spread* sigue un AR(1): $Z_t = \mu + \phi Z_{t-1} + \varepsilon_t$ con $|\phi| < 1$. Calcule la media, varianza y el tiempo esperado de retorno a la media $\mathbb{E}[\tau_\mu]$.
- (d) Para $\phi = 0.95$, $\mu = 0$, $\sigma = 0.01$: calcule el valor esperado y la desviación estándar del *spread*, y argumente cuándo es rentable abrir la posición de arbitraje.

3. Modelos SARIMA y estacionalidad

Definiciones y notación — SARIMA

Modelo SARIMA $(p, d, q)(P, D, Q)_s$.

$$\Phi_P(B^s) \phi_p(B) (1 - B^s)^D (1 - B)^d Y_t = \Theta_Q(B^s) \theta_q(B) \varepsilon_t,$$

donde s es el periodo estacional, $\phi_p(B) = 1 - \phi_1 B - \dots - \phi_p B^p$, $\Phi_P(B^s) = 1 - \Phi_1 B^s - \dots - \Phi_P B^{sP}$, y análogamente para θ_q y Θ_Q .

Diferencia estacional. $\Delta_s Y_t = Y_t - Y_{t-s} = (1 - B^s) Y_t$.

Patrones estacionales en ACF/PACF.

- Parte AR estacional Φ_P : PACF se corta en los rezagos $s, 2s, \dots, Ps$; ACF decae en múltiplos de s .
- Parte MA estacional Θ_Q : ACF se corta en los rezagos $s, 2s, \dots, Qs$; PACF decae.
- Necesidad de Δ_s : ACF muestral con picos persistentes en $s, 2s, 3s, \dots$

Modelo de Airline (Box-Jenkins). SARIMA(0, 1, 1)(0, 1, 1)₁₂: $(1 - B)(1 - B^{12})Y_t = (1 + \theta_1 B)(1 + \Theta_1 B^{12})\varepsilon_t$. Muy usado en series de ventas y transporte con datos mensuales.

Pronóstico con SARIMA. El pronóstico a horizonte h se obtiene acumulando las diferencias no estacional y estacional hacia adelante, usando las ecuaciones de recurrencia del modelo.

Ejercicio 3.1 (SARIMA $(p, d, q)(P, D, Q)_s$: estructura y notación). (a)

Para datos mensuales ($s = 12$), escriba explícitamente el modelo SARIMA(1, 1, 1)(1, 1, 1)₁₂ expandiendo todos los operadores.

- (b) Calcule $\Delta_{12}(\Delta_1 Y_t)$ en términos de rezagos de Y_t y muestre que involucra $Y_t, Y_{t-1}, Y_{t-12}, Y_{t-13}$.
- (c) Describa los patrones de ACF y PACF que sugieren necesidad de diferenciación estacional: ¿qué ocurre con $\rho(12)$, $\rho(24)$, $\rho(36)$ antes y después de aplicar Δ_{12} ?
- (d) En datos de ventas minoristas mensuales, ¿qué combinación (d, D) suele ser apropiada? Argumente con criterios de estacionariedad y parsimonia.

Ejercicio 3.2 (SARIMA para ventas mensuales: modelo de *Airline*). Una cadena registra ventas V_t (millones MXN) durante $T = 60$ meses. Se ajusta SARIMA(0, 1, 1)(0, 1, 1)₁₂:

$$(1 - B)(1 - B^{12})V_t = (1 + \theta_1 B)(1 + \Theta_1 B^{12})\varepsilon_t.$$

- Expanda el lado izquierdo: muestre que $(1 - B)(1 - B^{12})V_t = V_t - V_{t-1} - V_{t-12} + V_{t-13}$.
- Expanda el lado derecho y escriba la ecuación completa del modelo en términos de V_t , sus rezagos y los errores.
- Con $\hat{\theta}_1 = -0.4$, $\hat{\Theta}_1 = -0.6$ y los valores $V_{60} = 50$, $V_{59} = 45$, $V_{48} = 40$, $V_{47} = 35$, $\hat{\varepsilon}_{60} = 2$, $\hat{\varepsilon}_{48} = 1$, calcule el pronóstico $\hat{V}_{61}$.
- Construya el intervalo de predicción al 95% para V_{61} y V_{73} (misma posición estacional al año siguiente). ¿Por qué el intervalo crece con el horizonte?

Ejercicio 3.3 (SARIMA para tasas de interés con ciclos trimestrales). La tasa de rendimiento de CETES a 28 días se registra semanalmente con un ciclo trimestral ($s = 13$ semanas) ligado al calendario fiscal.

- Proponga un modelo SARIMA(p, d, q)(P, D, Q)₁₃ y argumente los órdenes elegidos usando el análisis de ACF/PACF estacional (picos en rezagos 13, 26, 39, ...).
- Una vez ajustado el modelo, calcule el pronóstico para las próximas 4 semanas y construya los intervalos de predicción al 80% y 95%.
- Evalúe el modelo con el ECMP en una muestra de validación de las últimas 26 semanas. Compare con un ARIMA(1, 1, 0) sin componente estacional.
- En un esquema de *trading* de tasas, el pronóstico de la tasa en $t + 1$ ayuda a decidir si comprar o vender futuros de CETES. Formule la regla de decisión basada en el intervalo de predicción y discuta el riesgo del modelo.

Ejercicio 3.4 (Descomposición STL y limpieza de estacionalidad). La descomposición STL separa $Y_t = T_t + S_t + R_t$ (tendencia, estacional, residuo).

- Explique las ventajas de STL frente a la descomposición clásica aditiva y X-12-ARIMA: robustez ante atípicos, componente estacional variable en el tiempo y flexibilidad del ancho de ventana.

- (b) Sea $Y_t = T_t + S_t + R_t$ con $T_t = 2 + 0.1t$ y $S_t = 3 \sin(2\pi t/12)$. Calcule la serie desestacionalizada $Y_t^{\text{des}} = Y_t - S_t$ e identifique sobre qué componente se ajusta el ARIMA.
- (c) En precios de *commodities* (e.g. gas natural con estacionalidad invernal), explique cómo STL+ARIMA mejora el pronóstico frente a un ARIMA directo.
- (d) Proponga el indicador de fuerza estacional $FS = \max\left(0, 1 - \frac{\text{Var}(R_t)}{\text{Var}(S_t + R_t)}\right)$. Interprete $FS \approx 0$ y $FS \approx 1$.

4. Modelos SARIMAX con variables exógenas

Definiciones y notación — ARIMAX / SARIMAX

Modelo ARIMAX (p, d, q) . $\phi_p(B)(1-B)^d Y_t = \beta^T \mathbf{x}_t + \theta_q(B)\varepsilon_t$, donde $\mathbf{x}_t \in \mathbb{R}^k$ son variables exógenas observadas en t .

Diferencia con regresión clásica. En el ARIMAX los errores $u_t = \theta_q(B)\varepsilon_t$ son ARMA, no i.i.d. Usar MCO ignorando la correlación produce estimadores ineficientes e inferencia inválida.

Estimación. Por máxima verosimilitud (MV) condicional, maximizando $\ell(\phi, \theta, \beta, \sigma^2) = \sum_t \log p(y_t | y_{t-1}, \dots, y_1, \mathbf{x}_t; \theta)$.

Selección de variables exógenas. Comparar AIC/BIC con y sin cada regresor; verificar la ausencia de multicolinealidad mediante el Factor de Inflación de la Varianza ($FIV_j = 1/(1 - R_j^2)$); problemático si $FIV > 10$).

SARIMAX. Combina la estructura SARIMA con regresores exógenos: $\Phi_P(B^s)\phi_p(B)(1-B^s)^D(1-B)^d Y_t = \beta^T \mathbf{x}_t + \Theta_Q(B^s)\theta_q(B)\varepsilon_t$.

Ejercicio 4.1 (ARIMAX: incorporación de variables exógenas). (a) Explique la diferencia entre un ARIMA con variables exógenas y una regresión lineal clásica con errores correlacionados. ¿Por qué no es correcto usar MCO cuando los errores son ARMA?

(b) Sea Y_t el tipo de cambio MXN/USD y x_t el diferencial de tasas México-EE.UU. Proponga un modelo ARIMAX(1, 1, 0) y argumente los signos esperados del coeficiente β .

(c) Derive las condiciones de estacionariedad para el proceso ARMAX, con-

siderando tanto las raíces del polinomio AR como el comportamiento de x_t .

- (d) Compare los criterios AIC y BIC del ARIMAX frente al ARIMA puro para determinar si la variable exógena mejora el ajuste. ¿Cuál criterio usaría para selección de modelo?

Ejercicio 4.2 (SARIMAX para demanda de energía eléctrica). La demanda horaria D_t tiene doble estacionalidad (diaria $s_1 = 24$, semanal $s_2 = 168$). Se incluye la temperatura Temp_t como variable exógena:

$$\phi(B)(1 - B^{24})(1 - B)D_t = \beta_0 + \beta_1 \text{Temp}_t + \theta(B)\varepsilon_t.$$

- (a) Justifique los órdenes de diferenciación y estacionalidad propuestos. ¿Qué signo espera para β_1 en verano vs. invierno?
- (b) La estimación por MV condicional requiere la log-verosimilitud. Enuncie cómo se construye a partir de la distribución condicional $p(y_t \mid y_{t-1}, \dots, y_1, \mathbf{x}_t; \boldsymbol{\theta})$.
- (c) Con los parámetros estimados y datos hasta la hora T , calcule $\hat{D}_{T+h}$ para $h = 1, \dots, 24$. ¿Cómo se tratan los valores futuros Temp_{T+h} ?
- (d) Calcule el ECMP para las últimas 72 horas y compare con el modelo *naïve* estacional $\hat{D}_{T+h} = D_{T+h-168}$.

Ejercicio 4.3 (SARIMAX para ventas con efectos de calendario). Las ventas semanales V_t de una cadena de supermercados tienen estacionalidad anual ($s = 52$) y se ven afectadas por días festivos F_t (dummy) y precio del petróleo P_t :

$$(1 - B)(1 - B^{52}) \log V_t = \beta_1 F_t + \beta_2 \Delta \log P_t + (1 + \theta B)(1 + \Theta B^{52})\varepsilon_t.$$

- (a) Interprete los coeficientes β_1 y β_2 .
- (b) Explique por qué se transforma $V_t \rightarrow \log V_t$: estabilización de la varianza, interpretación porcentual de los parámetros y mejor ajuste de la distribución de los errores.
- (c) Evalúe la multicolinealidad entre F_t y P_t usando el FIV. ¿Cuándo es problemática y cómo se resuelve?
- (d) Para un horizonte de 12 semanas, construya el pronóstico puntual e intervalos de predicción, asumiendo F_{T+h} conocido (calendario) y P_{T+h} modelado por un AR(1) separado. Cuantifique la incertidumbre adicional por la

predicción de P_{T+h} .

5. Simulación, Yule-Walker e interpretación gráfica

Definiciones y notación — Yule-Walker y diagnóstico

Ecuaciones de Yule-Walker para AR(p). $\gamma(k) = \sum_{j=1}^p \phi_j \gamma(k-j)$ para $k = 1, \dots, p$. En forma matricial: $\mathbf{\Gamma}_p \boldsymbol{\phi} = \boldsymbol{\gamma}_p$, donde $\mathbf{\Gamma}_p$ es la matriz de Toeplitz de autocovarianzas y $\boldsymbol{\gamma}_p = (\gamma(1), \dots, \gamma(p))^T$. La varianza del ruido blanco: $\sigma^2 = \gamma(0) - \boldsymbol{\phi}^T \boldsymbol{\gamma}_p$.

Estimación Yule-Walker. Sustituir $\gamma(k)$ por la autocovarianza muestral $\hat{\gamma}(k) = \frac{1}{T} \sum_t Y_t Y_{t-k}$: $\hat{\boldsymbol{\phi}} = \hat{\mathbf{\Gamma}}_p^{-1} \hat{\boldsymbol{\gamma}}_p$. El estimador es consistente y asintóticamente normal.

Representación MA(∞). Coeficientes $\{\psi_j\}$ de la representación $Y_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}$: $\psi_0 = 1$, $\psi_j = \sum_{k=1}^{\min(j,p)} \phi_k \psi_{j-k}$.

ECM de predicción a horizonte h . $\text{MSE}_h = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2$.

Bandas de significancia en ACF/PACF. Bajo H_0 : ruido blanco, $\hat{\rho}(k) \stackrel{\text{aprox.}}{\sim} \mathcal{N}(0, 1/T)$. Banda al 95%: $\pm 1.96/\sqrt{T}$.

Criterio para raíces complejas. Si el polinomio AR(p) tiene raíces complejas, la ACF teórica presenta oscilaciones amortiguadas (componente senoidal); la frecuencia de oscilación corresponde al argumento de las raíces complejas.

Método de bootstrap paramétrico. Para cuantificar incertidumbre en pronósticos: (1) estimar el modelo; (2) simular B trayectorias futuras muestreando $\varepsilon^{(b)} \sim \mathcal{N}(0, \hat{\sigma}^2)$; (3) tomar percentiles 2.5% y 97.5% de $\{Y_{T+h}^{(b)}\}$.

Ejercicio 5.1 (Ecuaciones de Yule-Walker y estimación AR). Para un AR(p) estacionario $Y_t = \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + \varepsilon_t$.

- Derive las ecuaciones de Yule-Walker para un AR(1): muestre que $\phi_1 = \gamma(1)/\gamma(0) = \rho(1)$ y que $\sigma^2 = \gamma(0)(1 - \phi_1^2)$.
- Para un AR(2) con $\phi_1 = 0.6$, $\phi_2 = -0.2$, resuelva el sistema Yule-Walker para obtener $\gamma(0)$, $\gamma(1)$ y $\gamma(2)$ en términos de σ^2 .
- Explique por qué el estimador Yule-Walker es consistente y cómo se usa la descomposición de Cholesky de la matriz de Toeplitz $\hat{\mathbf{\Gamma}}_p$ para resolverlo eficientemente.

- (d) La siguiente tabla muestra autocorrelaciones muestrales de log-retornos diarios del IPC ($T = 1,000$):

Rezago k	1	2	3	4	5	10	20
$\hat{\rho}(k)$	0.12	-0.04	0.07	0.02	-0.03	0.01	0.00

Aplice Yule-Walker con $p = 1$ y $p = 2$ para estimar los parámetros AR. Construya el IC al 95% para $\rho(1)$ y determine si es estadísticamente significativo.

Ejercicio 5.2 (Simulación de un AR(2) y diagnóstico gráfico). Se simulan $T = 300$ observaciones de $Y_t = 0.7Y_{t-1} - 0.3Y_{t-2} + \varepsilon_t$, $\varepsilon_t \sim \mathcal{N}(0, 1)$. La ACF muestral da $\hat{\rho}(1) = 0.61$ y $\hat{\rho}(2) = 0.22$.

- Identifique el orden del modelo a partir del patrón de ACF y PACF: ¿en qué rezago se corta la PACF? ¿Qué patrón sigue la ACF? Justifique la consistencia con un AR(2).
- Use las ecuaciones de Yule-Walker con $\hat{\rho}(1) = 0.61$ y $\hat{\rho}(2) = 0.22$ para estimar $\hat{\phi}_1$ y $\hat{\phi}_2$. Compare con los valores verdaderos.
- Las raíces del polinomio $1 - 0.7z + 0.3z^2 = 0$ son complejas. Calcúlelas y determine su módulo. ¿Qué implica que las raíces sean complejas para la forma de la ACF teórica?
- Calcule la varianza teórica $\gamma(0)$ del proceso usando la fórmula del Ejercicio 5.1 y compárela con la varianza muestral.

Ejercicio 5.3 (Tabla de rendimientos y ajuste ARIMA a log-retornos del IPC). La siguiente tabla presenta estadísticas de log-retornos diarios del IPC:

Periodo	Media	Des. Est.	Asim.	Curtosis	$\hat{\rho}(1)$	$\hat{\rho}(5)$
Ene-Jun 2020	-0.0008	0.0221	-0.87	6.23	0.08	-0.03
Jul-Dic 2020	0.0012	0.0148	-0.42	4.11	0.12	0.05
Ene-Jun 2022	-0.0003	0.0131	0.21	3.85	0.06	-0.02
Jul-Dic 2023	0.0009	0.0117	-0.18	3.44	0.09	0.01

- Interprete la tabla: ¿en qué periodo fue mayor la volatilidad? ¿Cuál tuvo mayor asimetría negativa? ¿Qué valores de curtosis indican colas más gruesas?

sas que la normal? Relacione con eventos macroeconómicos.

- (b) Con $\hat{\rho}(1) = 0.12$ del periodo Jul–Dic 2020, estime $\hat{\phi}_1$ y $\hat{\sigma}^2$ para un AR(1) por Yule-Walker. Construya el IC al 95% para ϕ_1 .
- (c) Para Ene–Jun 2020, con $\hat{\rho}(1) = 0.08$ y curtosis 6.23, ¿es apropiado un ARIMA(1, 0, 0) para modelar los log-retornos? ¿Qué evidencia de heteroscedasticidad condicional presenta la tabla y qué extensión del modelo requeriría?
- (d) Simule 126 observaciones de un AR(1) con $\phi_1 = 0.12$ y $\sigma = 0.0148$. Calcule la ACF muestral del simulado y compárela con la ACF teórica $\rho(k) = 0.12^k$. ¿A qué se deben las discrepancias?

Ejercicio 5.4 (Simulación SARIMA y diagnóstico estacional). Se simulan $T = 120$ observaciones del SARIMA(0, 0, 1)(1, 0, 0)₁₂: $(1 - \Phi_1 B^{12})Y_t = (1 + \theta_1 B)\varepsilon_t$, $\Phi_1 = 0.8$, $\theta_1 = -0.5$, $\varepsilon_t \sim \mathcal{N}(0, 1)$. La ACF simulada presenta picos en $k = 12, 24, 36$ con valores aproximados 0.72, 0.55, 0.41.

- (a) Interprete la ACF: ¿qué indica la presencia de picos en los rezagos 12, 24 y 36? ¿Por qué decaen progresivamente? Vincule con la parte AR estacional $\Phi_1 = 0.8$.
- (b) Calcule la ACF teórica en los rezagos $k = 1, 12, 13, 24$ usando las propiedades del modelo, incluyendo la contribución del término MA(1).
- (c) A partir de la ACF observada, proponga el orden del modelo SARIMA(p, d, q)(P, D, Q)₁₂ siguiendo el procedimiento de Box-Jenkins. ¿Hay evidencia de necesitar diferenciación?
- (d) Calcule el error de estimación Yule-Walker para Φ_1 usando $\hat{\Phi}_1 = \hat{\rho}(12) = 0.72$ y compare con el valor verdadero 0.8. ¿Por qué hay sesgo hacia abajo con muestras pequeñas?

Ejercicio 5.5 (Pronóstico con intervalos: tabla comparativa de modelos). La siguiente tabla compara tres modelos ajustados al tipo de cambio MXN/USD ($n = 36$ meses; muestra de prueba: últimos 6 meses):

Modelo	AIC	BIC	RMSE	MAE	$\hat{\sigma}^2$	Pars.
ARIMA(1, 1, 0)	-48.2	-45.1	0.341	0.278	0.0118	1
ARIMA(1, 1, 1)	-51.7	-47.0	0.312	0.251	0.0103	2
SARIMA(1, 1, 1)(1, 0, 1) ₁₂	-54.3	-47.8	0.298	0.239	0.0098	4

- (a) Interprete la tabla: ¿cuál modelo tiene mejor ajuste dentro de muestra según AIC y BIC? ¿Coinciden los dos criterios? ¿Cuál predice mejor fuera de muestra?
- (b) ¿Por qué la banda de confianza se expande con el horizonte? Calcule la amplitud del IC al 95% en $h = 6$ usando $2 \times 1.96 \times \hat{\sigma}\sqrt{h}$ (aproximación ARIMA(1, 1, 0)).
- (c) Con $\hat{\phi}_1 = 0.3$, $\hat{\theta}_1 = -0.4$, $\Delta Y_T = 0.16$ y $\hat{\varepsilon}_T = 0.05$, calcule explícitamente $\hat{Y}_{T+1|T}$ y $\hat{Y}_{T+2|T}$.
- (d) Una empresa importadora necesita comprar dólares en 3 meses. Explique cómo usar el intervalo de predicción del SARIMA para fijar una cobertura cambiaria (*forward* o *put*). ¿Prefiere el punto central o el percentil 95%?

Ejercicio 5.6 (Simulación de Monte Carlo para evaluación de pronósticos). El método de bootstrap paramétrico para un ARIMA(p, d, q): (1) estimar el modelo; (2) generar $B = 10,000$ trayectorias futuras muestreando $\varepsilon^{(b)} \sim \mathcal{N}(0, \hat{\sigma}^2)$; (3) tomar los percentiles 2.5% y 97.5% como intervalo.

- (a) Para el AR(1) con $\phi_1 = 0.6$ y $\sigma = 1$, demuestre que

$$Y_{T+h} \mid Y_T = y_0 \sim \mathcal{N}\left(\phi_1^h y_0, \sigma^2 \frac{1 - \phi_1^{2h}}{1 - \phi_1^2}\right).$$

- (b) Calcule el IC analítico al 95% para $h = 1, 5, 10$ con $y_0 = 2$ y complete la tabla:

h	$\mathbb{E}[Y_{T+h}]$	$\text{Var}(Y_{T+h})$	LI 95%	LS 95%
1				
5				
10				
∞				

Observe cómo la media converge a 0 y la varianza a $\sigma^2/(1 - \phi_1^2)$.

- (c) Describa el algoritmo de Monte Carlo para replicar los intervalos de la tabla anterior. Simule $B = 1,000$ trayectorias y compare el intervalo empírico con el analítico. ¿Cuánta diferencia hay?
- (d) Interprete el *fan chart* (abanico de pronósticos): ¿por qué se abre el abanico? ¿Hacia dónde converge la media? ¿Qué le pasa a la incertidumbre cuando $h \rightarrow \infty$?